

Resumen

En este documento se presentan dos ejemplos de implementación de algoritmos de clasificación: regresión logística y Naive Bayes. Ambos ejemplos generan datos sintéticos, entrenan los modelos con estos datos, visualizan las predicciones y evalúan la precisión de los modelos.

Palabras Clave

Regresión Logística, Naive Bayes, Datos Sintéticos, Clasificación. Precisión del Modelo

Introducción

La clasificación es una tarea fundamental en el aprendizaje automático, donde el objetivo es asignar etiquetas a instancias basadas en sus características. Dos métodos populares para la clasificación son la regresión logística y Naive Bayes. En este documento, se presentan ejemplos de cómo generar datos sintéticos, ajustar estos modelos y evaluar su desempeño.

Desarrollo

Regresión Logística

Generación de Datos Sintéticos: Se crean 200 muestras divididas en dos clases utilizando una distribución normal. Las muestras de una clase se desplazan en una dirección positiva, mientras que las de la otra clase se desplazan en la dirección opuesta.

```
rng(0);  
n = 100;  
X = [randn(n, 2) + 1; randn(n, 2) - 1];  
y = [ones(n, 1); zeros(n, 1)];
```

Visualización de los Datos: Los datos generados se visualizan en un gráfico de dispersión.

```
figure;  
gscatter(X(:,1), X(:,2), y, 'rg', '*+');
```

Equipo: los Gepetos

Integrantes: Farrera Mendez Emmanuel Sinai - Hernández Hernández Jorge Gabriel

Grupo: 6CM2

Asignatura: Inteligencia Artificial

Practica 07: Regresión logística y Bayes

Ajuste del Modelo: Se ajusta un modelo de regresión logística utilizando las características y etiquetas generadas.

```
data = array2table(X, 'VariableNames', {'Caracteristica1', 'Caracteristica2'});  
data.Respuesta = y;  
modelo = fitglm(data, 'Respuesta ~ Caracteristica1 + Caracteristica2', 'Distribution'
```

Predicción y Evaluación: Se predicen las probabilidades y se convierten a etiquetas. Luego, se calcula la precisión del modelo.

```
probabilidades = predict(modelo, data);  
predicciones = round(probabilidades);  
precision = mean(predicciones == y);  
fprintf('Precisión del Modelo: %.2f%%\n', precision * 100);
```

Visualización de las Predicciones: Se visualizan las predicciones del modelo.

```
figure;  
gscatter(X(:,1), X(:,2), predicciones, 'rg', '*+');
```

Naive Bayes

Generación de Datos Sintéticos: Similar a la regresión logística, se crean 200 muestras divididas en dos clases.

```
rng(1);  
n = 100;  
X = [randn(n, 2) + 1; randn(n, 2) - 1];  
y = [ones(n, 1); zeros(n, 1)];
```

Visualización de los Datos: Se visualizan los datos generados.

```
figure;  
gscatter(X(:,1), X(:,2), y, 'rb', '*o');
```

Equipo: los Gepetos

Integrantes: Farrera Mendez Emmanuel Sinai - Hernández Hernández Jorge Gabriel

Grupo: 6CM2

Asignatura: Inteligencia Artificial

Practica 07: Regresión logística y Bayes

Entrenamiento del Modelo: Se entrena un modelo de Naive Bayes con los datos generados.

```
naiveBayesModel = fitcnb(X, y);
```

Predicción y Evaluación: Se predicen las etiquetas y se evalúa la precisión del modelo.

```
predicciones = predict(naiveBayesModel, X);  
precision = mean(predicciones == y);  
fprintf('Precisión del Modelo: %.2f%%\n', precision * 100);
```

Visualización de las Predicciones y Frontera de Decisión: Se visualizan las predicciones y la frontera de decisión del modelo.

```
d = 0.1;  
[x1Grid, x2Grid] = meshgrid(min(X(:,1)):d:max(X(:,1)), min(X(:,2)):d:max(X(:,2)));  
xGrid = [x1Grid(:), x2Grid(:)];  
prediccionesGrid = predict(naiveBayesModel, xGrid);  
  
figure;  
gscatter(X(:,1), X(:,2), y, 'rb', '*o');  
hold on;  
prediccionesGridBin = double(prediccionesGrid);  
prediccionesGridBin(prediccionesGridBin == 0) = 2;  
gscatter(xGrid(:,1), xGrid(:,2), prediccionesGridBin, 'yg', '.', [], 'off');
```

Equipo: los Gepetos

Integrantes: Farrera Mendez Emmanuel Sinai - Hernández Hernández Jorge Gabriel


Grupo: 6CM2

Asignatura: Inteligencia Artificial

Practica 07: Regresión logística y Bayes

Análisis y Resultados

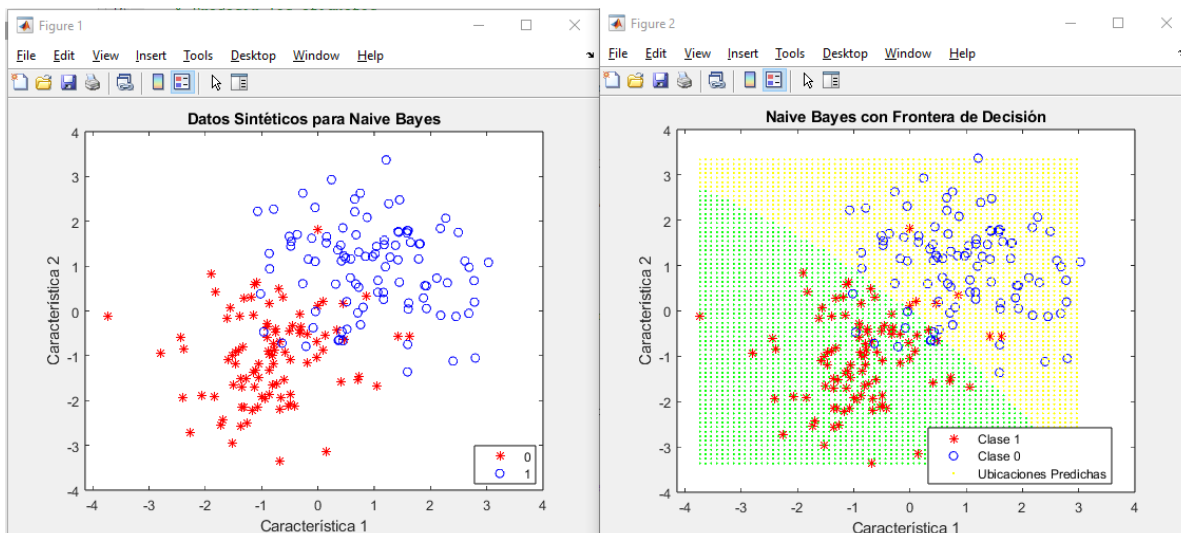
Regresión Logística: La regresión logística logró una precisión alta al clasificar correctamente la mayoría de las muestras. La visualización mostró una clara separación entre las clases.



Estimated Coefficients:

	Estimate	SE	tStat	pValue
(Intercept)	0.34429	0.32956	1.0447	0.29616
Caracteristica1	2.3183	0.45527	5.0922	3.5398e-07
Caracteristica2	2.6285	0.51548	5.0992	3.4114e-07

Naive Bayes: El modelo de Naive Bayes también logró una precisión alta, con una frontera de decisión bien definida. Las predicciones se visualizaron efectivamente con la malla creada para mostrar la frontera.



Equipo: los Gepetos

Integrantes: Farrera Mendez Emmanuel Sinai - Hernández Hernández Jorge Gabriel

Grupo: 6CM2

Asignatura: Inteligencia Artificial

Practica 07: Regresión logística y Bayes

Ambos métodos demostraron ser efectivos para la clasificación binaria con datos sintéticos, cada uno con sus propias ventajas en términos de interpretabilidad y simplicidad.

Referencias

Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer.